

# 基于无人机遥感影像的松材线虫病监测方法概述

李卫斌<sup>1,2</sup>, 安炳贞<sup>1,2</sup>, 孔玉辉<sup>1,2</sup>, 杜建超<sup>3</sup>

(1. 西安电子科技大学人工智能学院, 西安 710075; 2. 西安电子科技大学北斗时空智能研究中心, 西安 710075; 3. 西安电子科技大学通信工程学院, 西安 710075)

**摘要:**松树是我国森林资源中重要的组成树种之一, 占我国人工林面积的 70%以上, 但近几年松树资源受外来有害生物松材线虫的侵害, 大量松树死亡, 给我国林业生产和生态环境造成了巨大的经济损失。鉴于松材线虫致病力强、发病时间短、传播速度快、治理难度大等特点, 目前最有效的办法是及时发现和准确定位被松材线虫病感染的疫木并及时处置。人工踏查和卫星遥感在复杂林区监测方面存在局限性。无人机遥感以其实时、低成本和高空间分辨率的优点被广泛应用于农林业低空遥感, 目前多使用无人机遥感影像开展松材线虫罹病木监测。笔者全面总结近几年使用人工特征提取算法和深度学习算法在松材线虫病识别领域的相关研究, 从准确率、召回率、精确率等指标以及数据集等多方面对各种处理方法进行对比分析。从现有研究成果来看, 基于 Inceptionv3 和 AdaBoost 算法的检测模型, 其泛化能力和识别精度优于其他算法, 但基于 Faster R-CNN 和 YOLOv4 算法能够识别不同感染阶段的罹病木。通过结合无人机遥感和深度学习算法能监测受害区域染病松树的生长现状和分布情况, 为后续罹病木的处理提供了支持。未来, 融合深度学习与传统机器学习的优点, 结合多传感器的遥感数据协同监测林业病虫害将成为趋势。

**关键词:**林业病虫害; 松材线虫; 遥感监测; 深度学习; 无人机影像

中图分类号:S763 文献标志码:A 文章编号:2096-1359(2023)02-0021-09

## A review of monitoring methods for pine wilt disease based on UAV remote sensing images

LI Weibin<sup>1,2</sup>, AN Bingzhen<sup>1,2</sup>, KONG Yuhui<sup>1,2</sup>, DU Jianchao<sup>3</sup>

(1. School of Artificial Intelligence, Xidian University, Xi'an 710075, China; 2. Beidou Space-Time Intelligence Research Center, Xidian University, Xi'an 710075, China; 3. School of Communication Engineering, Xidian University, Xi'an 710075, China)

**Abstract:** The pine tree is one of the important constituent tree species in China's forest resources. It accounts for more than 70% of the plantation area in China. However, in recent years, pine resources have been infringed by exotic pests of pine wood nematodes, resulting in the death of a large number of pine trees. The emergence of pine wood nematode has created a great impact on Chinese forestry production and ecological environments, causing huge economic losses to the pine wood forestry. Considering the characteristics of pine wilt disease caused by pine wood nematodes such as the strong pathogenicity, short onset time, fast-spreading speed, and high difficulty in treatment, the most effective way to control the spread of pine wilt disease at present is to timely detect and accurately locate diseased trees infected with pine wilt disease. Traditional monitoring methods such as manual surveys and satellite remote sensing have limitations in monitoring complex forest areas. Due to the advantages of real-time, low cost, and high spatial resolution of the unmanned aerial vehicle (UAV) remote sensing, UAVs are widely used in the low-altitude remote sensing in the agriculture and forestry. At present, the UAV remote sensing images are often used to monitor pine wilt disease trees. This article comprehensively summarizes the latest algorithms in the field of pine wilt disease identification, such as artificial feature extraction algorithms and deep learning algorithms in recent years. After comparing and analyzing their advantages and disadvantages from the view of accuracy, recall, precision, and dataset, the methods based on Inceptionv3 and AdaBoost are better than others for their generalization ability and recognition accuracy according to the existing research results. However, the diseased trees at different stages of infection can be identified using the Faster R-CNN (Faster Region Convolutional Neural Networks) and YOLOv4 (You Only Look Once v4) algorithms.

收稿日期:2022-03-04

修回日期:2022-04-26

基金项目:宁夏回族自治区重点研发计划(东西部合作专项)(2020BFG02013);陕西省重点研发计划项目(2021GY-102);西安市科技计划项目(21RGZN0012)。

作者简介:李卫斌,男,教授,研究方向为遥感影像智能处理等。E-mail:weibinli@xidian.edu.cn

By combining UAV remote sensing and deep learning algorithms, the growth status and distribution of infected pine trees in the epidemic area can be monitored, which provides support for the subsequent treatment of diseased trees. In the future, the deep learning and traditional machine learning will be combined with multi-sensor remote sensing data to collaboratively detect forestry pests and diseases.

**Keywords:** forestry pest and disease; pine wilt disease; remote sensing monitoring; deep learning; UAV image

森林资源是全球最重要的自然资源之一,然而近年来随着全球气候变暖,受森林火灾、乱砍滥伐、病虫害等方面的影响,我国的森林资源利用与可持续发展受到严重威胁。我国主要林业有害生物包括松材线虫(*Bursaphelenchus xylophilus*)、美国白蛾(*Hyphantria cunea*)和薇甘菊(*Mikania micrantha*)等。近几年松材线虫病(pine wilt disease, PWD)疫情呈快速扩散蔓延态势,已经成为全球森林草原生态系统中最具危险性、毁灭性的病害<sup>[1-3]</sup>(图1)。目前主要分布于美国、法国、加拿大、墨西哥、韩国、朝鲜、日本、葡萄牙和中国9个国家,该病主要危害松类树种,通过自然传播(松墨天牛等)和人为传播两种方式扩散<sup>[4-5]</sup>。自1982年首次在南京中山陵发现松材线虫病以来,我国感染松材线虫病的松树种类和数量就不断增多,尤其2017年以来松材线虫病发生面积快速增大。我国目前共有19个省(区、市)735个县级行政区受到松材线虫病的侵害<sup>[6]</sup>。

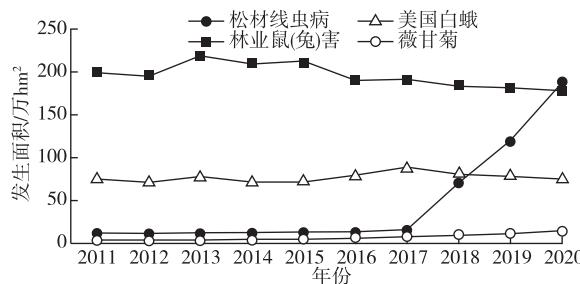


图1 2011—2020年4种主要林业有害生物发生情况<sup>[2]</sup>

Fig. 1 Occurrences of four major forestry pests from 2011 to 2020

健康松树在正常情况下从染病、变色到枯死仅需2个月左右的时间。目前主要通过树脂分泌、生长活力和针叶的颜色来确定感染阶段。从针叶的颜色上来看,墨绿色针叶的健康松树在受到松材线虫病胁迫后,针叶开始变黄(早期),大部分针叶陆续变为黄褐色(中期),然后松树干枯针叶全部变为红褐色(晚期),最后整株枯死<sup>[7-9]</sup>。研究表明,由于叶绿素和水分含量的不同,健康松树和不同感染阶段的罹病木之间光谱曲线差异明显,这为基于遥感的松材线虫病识别提供了重要的基础<sup>[10-12]</sup>。

松材线虫病的防治包括疫情普查、疫木除治、媒介昆虫防治、检疫封锁和疫木处理等措施<sup>[13]</sup>。4

月初是松墨天牛羽化初期和盛期<sup>[14]</sup>,此时为松材线虫数量增长高峰期;9月上旬是松墨天牛幼虫期,具有非传播期、易防治等特点。因此多在每年春秋季节对疫区松材线虫病开展疫情普查<sup>[15]</sup>。现阶段林业病虫害防治工作中主要有五大缺陷:一是缺乏强有效的监测预警机制;二是病虫害发病机理与传播机理研究不够完善;三是大面积使用化学农药防治,不利于生态保护和可持续发展;四是缺乏科学的防治策略及科学手段对疫情和防治策略进行评估;五是病虫害监测技术手段较为薄弱,还不具备及时、准确、智能化、大范围的疫情掌握能力。无人机遥感技术能够实时、快速获取林业病虫害高分辨率影像数据,考虑其飞行时间灵活、飞行高度可控等优点,笔者主要对基于无人机遥感影像的松材线虫病自动监测技术进行综述。

虽然无人机遥感技术在林业病虫害监测已显现出其所具有的优势,但在实际的应用中还存在多方面的不足。如无人机影像受地形起伏影响,影像地面分辨率存在差异,海拔变化大会导致无人机影像重叠度过高,起飞降落不便且续航时间较短<sup>[16]</sup>。另外,无人机影像由于受飞行高度、相机视角的影响,单张无人机影像所覆盖的区域面积不大,在特定任务中需要对多张影像进行拼接,从而导致拼接工作量大、精度低、易出现偏差等问题<sup>[17]</sup>,且在无人机图像处理过程中,对于较稠密的林区,图像拼接存在变形,导致树木定位精度不高;因此无人机林业病虫害监测技术适应于地形起伏程度较小的林区,且不适合密林覆盖的区域。

早期的松材线虫病图像识别方法依赖于从图像中提取人工设计特征,使用这些特征来训练浅层分类器算法,如支持向量机、随机森林、人工神经网络等<sup>[18]</sup>,其主要步骤可分为4步:图像采集、图像预处理、特征提取、识别与分类。但早期识别方法难以提取高级语义特征,存在时间复杂度高、依赖人工设计特征、缺乏鲁棒性等问题。近年来,以自动特征提取的深度学习方法在图像识别领域取得极大的成功。不同于早期识别方法,深度学习网络具有强大的特征学习和特征表达能力,如AlexNet、GoogLeNet、R-CNN、YOLO等。考虑到无人机遥感影像中复杂背景的干扰问题,如红色阔叶树、裸土、

农田和枯死草地等,许多学者提出了基于人工设计特征和深度学习融合的松材线虫病识别方法来提高模型的识别精度。

## 1 图像处理技术在松材线虫病监测方法中的应用

### 1.1 松材线虫病遥感监测的精度评价方法

为了评价松材线虫病虫害检测模型的有效性,一般采用准确率(accuracy,  $A$ )、精确率(precision,  $P$ )、召回率(recall,  $R$ )、 $F_1$ 参数和平均精度(average precision,  $A_p$ )作为评价指标。TP(true positive,  $T_p$ )表示正样本被预测为正样本,FP(false positive,  $F_p$ )表示负样本被预测为正样本,FN(false negative,  $F_n$ )表示正样本被预测为负样本,TN(true negative,  $T_n$ )表示负样本被预测为负样本。

#### 1) 精确率、召回率和准确率。

$P$ 为预测为正样本中正确预测的比例;  $R$ 为实际正样本中正确预测为正样本的比例;  $A$ 为所有预测正确的样本占总样本的比例。计算公式如下:

$$P = \frac{T_p}{T_p + F_p} \times 100\% \quad (1)$$

$$R = \frac{T_p}{T_p + F_n} \times 100\% \quad (2)$$

$$A = \frac{T_p + T_n}{T_p + T_n + F_p + F_n} \times 100\% \quad (3)$$

2) 综合性能指标  $F_1$ -score、平均精度(AP)、均值平均精度( $M_{AP}$ )。

$F_1$ -score为精确率和召回率的调和平均数,可综合反映整体结果的质量。 $A_p$ 是衡量某一类别检测的平均精度值,利用精确率对召回率的积分。 $M_{AP}$ 是衡量所有类别检测精度的指标,指所有类别检测的平均精度值除以所有类别。计算公式如下:

$$F_1 = \frac{2PR}{P + R} \quad (4)$$

$$A_p = \int_0^1 P dR \quad (5)$$

$$M_{AP} = \left( \sum_c A_{pc} \right) / C \quad (6)$$

式中,  $C$ 为图像检测的类别数。

3) 生产者精度(PA)、用户精度(UA)、总体分类精度(OA)和Kappa系数。

UA是指每一类的预测结果中,正确分类的样本数量所占的比例;PA是指每一类中正确分类的样本数量占该类中所有样本数量的比例;Kappa系数是一种用于检验模型预测结果和实际分类结果

是否一致的指标,也是一种衡量分类精度的指标; $P_o$ 为每一类预测正确的样本数量占总样本数的比例,也叫做总体分类精度; $P_e$ 为每一类的实际样本数量与预测结果中该类样本数量的乘积和与总样本数平方之比。计算公式如下:

$$K_{app} = \frac{P_o - P_e}{1 - P_e} \quad (7)$$

$$P_o = (T_p + T_n) / (T_p + T_n + F_p + F_n) \quad (8)$$

$$P_e = [(T_n + F_n) \times (T_n + F_p) + (F_p + T_p) \times (F_n + T_p)] / (T_p + T_n + F_p + F_n)^2 \quad (9)$$

### 1.2 基于人工设计特征的松材线虫病监测方法

对遥感数据中的罹病木进行特征提取和识别分类是林业病虫害检测的主要任务。在计算机视觉领域,建立图像的特征表达是一个研究重点,较常用的图像特征有:颜色特征、纹理特征、形状特征、空间关系特征等。由于罹病木内部生理结构发生变化导致其外表也发生改变,其比较明显的区别在于其颜色和纹理特征。刘遐龄等<sup>[19]</sup>利用面向对象分类和多尺度分割方法提取松林目标区域,通过分析松树在不同感染阶段呈现的颜色和纹理特征,对不同感染阶段的罹病木设置了多个模板,在模板匹配算法(template matching, TM)中使用模糊C均值聚类的方法对样本进行初步分类,以及采用马氏距离作为识别的判断标准。阈值分割法是一种基于区域的经典图像分割方法,陶欢等<sup>[20]</sup>分析了不同背景下罹病木和其他地物在HSV色彩空间上的差异,设定松材线虫病不同通道的最优阈值范围,以此去除健康松树、其他阔叶树、枯死杂草、裸土、阴影等。从比较结果可以看出,HSV色彩空间比RGB效果更好,总体分类精度达到58%~65%。

Syifa等<sup>[21]</sup>证明了支持向量机(support vector machine, SVM)分类器比人工神经网络(artificial neural network, ANN)识别效果更好,从Kappa系数可以看出,SVM可以更好地将罹病木和其他类型地物进行分类。胡根生等<sup>[22]</sup>使用了一种基于像素的分类识别方法,从双光谱遥感图像样本中提取健康松树、罹病木和其他地物的颜色特征和局部特征。根据颜色特征使用阈值法去除部分健康松树,然后根据局部特征构建特征向量并使用加权小波支持向量数据描述(weighted wavelet support vector data description, WWSVDD)将测试样本进行分类识别。从实验结果可看出,该方法对于不同感染阶段的罹病木分类具有一定的可行性,总体分类精度最高达到94.92%。

在前期的研究中,只能识别出健康松树和罹病

木,但松树的病害等级并未实现。Yu 等<sup>[23]</sup>提出了基于高光谱影像(hyperspectral image, HI)和激光雷达(light detection and ranging, LiDAR)影像的一种森林健康监测方法,利用随机森林算法<sup>[24]</sup>(random forest, RF)识别不同感染阶段的罹病木树冠,发现同时使用 HI 和 LiDAR 影像对罹病木进行分类的总体分类精度(73.96%)要优于单独使用 HI(66.86%)和单独使用 LiDAR 影像(45.56%)。但 LiDAR 影像能够区分松树和红色阔叶树,精确地获得单个树冠直径和位置信息,尤其适用于识别晚期罹病木。Iordache 等<sup>[25]</sup>对获取的多光谱影像(multispectral image, MI)和高光谱影像也分别采用了一种基于 RF 算法的树冠像素分类算法。为了让罹病木在输出结果中更突出地显示,在使用区域生长分割算法提取树冠和随机森林算法进行分类之前,采用一种基于光谱数据、空间滤波和冠层高度模型的处理技术,其中冠层高度模型用于去除冠层高度较低的树木,光谱数据用于去除阴影部分,空间滤波用于去除噪声。从检测结果(图 2)可以看出健康松树到罹病木随时间的演变过程,其中

黄色代表健康的松树树冠像素,红色代表疑似染病的松树树冠像素,蓝色代表已确定染病的松树树冠像素。可以看出蓝色范围在不断地扩增,这表明罹病木处于更严重的感染阶段。

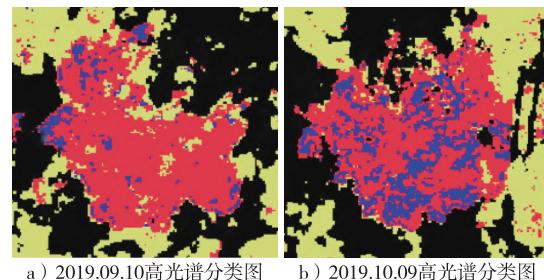


图 2 健康松树到罹病木时间演变图<sup>[25]</sup>

Fig. 2 Time evolution from healthy pine trees to disease trees

近几年使用人工特征提取方法在松材线虫病识别领域的相关研究,及每个方法所用的数据集、处理技术和优缺点见表 1,其中基于加权小波支持向量数据描述模型的总体分类精度最高,但计算量较大,效率较低。而随机森林算法可识别不同感染阶段的罹病木。

表 1 人工特征提取方法在松材线虫病识别中的应用比较

Table 1 Application comparison of artificial feature extraction methods in pine wilt disease identification

数据集	处理技术	优点	缺点	文献
535 个罹病木样本	面向对象分类提取松林区域,模板匹配用于分类	效率高于目视解译法	无法匹配旋转或大小发生变化的目标,对光照、亮度比较敏感;且不适合地物类型复杂的区域识别罹病木	[19]
183 个罹病木样本, 157 个其他地物样本	RGB 到 HSV 转换, 阈值去除健康松树和其他地物	实现简单, 计算量小, 考虑了不同背景下的松林	依赖于颜色特征,一旦出现裸地或与罹病木相近的物体等干扰时,仍会造成松材线虫病的误检;且目视判读易忽视体态较小的病木和影像阴影区	[20]
500 个罹病木像素, 1 200 个健康松树像素, 800 个其他地物像素	根据提取的颜色特征, 阈值去除部分健康松树;根据局部特征构造特征向量, 使用 WWSVDD 进行分类	可将病害松树与其他干扰地物进行分类	大量训练样本和基于像素的分类方法导致效率较低;且基于双光谱的方法需要配备不同波段的主动光源,对设备的要求高、成本高	[22]
健康松树:51。早期:50。中期:22。晚期:22。枯死松树:24。阔叶树:66	采用点云分割方法对 LiDAR 数据分割提取树冠, 采用基于对象的分割方法对 HI 提取树冠, 最后利用 RF 算法对树冠进行分类	可对不同感染阶段的罹病木进行分类。考虑了阴影、红色阔叶数和树冠遮挡带来的影响	对早期感染松树的识别精度较低(OA 为 50%, PA 为 64.1%);对高光谱数据的分割结果进行了手动调整,不适合大规模数据,且高分辨率数据来源成本相对较高	[23]
多光谱影像中有 78 个松树树冠样本, 高光谱影像中有 68 个松树树冠样本	采用基于光谱数据、空间滤波和冠层高度模型的处理技术去除干扰目标, 最后采用区域生长分割算法提取树冠和 RF 算法对树冠像素进行分类	可以看出健康松树到罹病木随时间的演变过程	多光谱和高光谱数据来源成本相对较高;没有考虑阔叶树带来的影响;效率较低且持续观察比较耗时,并且除松材线虫病感染外,其他因素也会导致松树变色。	[25]

### 1.3 基于深度学习的松材线虫病监测方法

近年来,卷积神经网络(convolutional neural network, CNN)图像分类和识别问题已逐渐成为当前的研究热点<sup>[26]</sup>。基于卷积神经网络的目标检测算法不断提出和改进,其检测精度和速度也在不断地提升。Tao 等<sup>[27]</sup>在纯林+平坦地形、纯林+复杂

地形以及混合人工林+红色阔叶树 3 个区域使用 CNN 和 TM 算法来检测松材线虫病,证明了与传统 TM 方法相比,CNN 实现了更高的识别准确率,由于纯林与平坦地形的背景干扰性低,其检测结果最好,纯林与复杂地形次之,混合人工林与红色阔叶树检测结果最差。李凤迪等<sup>[28]</sup>提出了一种基于

YOLOv3-CIoU 算法的松材线虫病检测模型,并构建了不同高度的罹病木数据。为解决 YOLOv3 模型在训练期间损失置空的问题,使预测框更接近真实框的位置,将兼容重叠率( compatible intersection over union, CIoU)损失函数作为损失函数替代原先 YOLOv3 模型所使用的均方误差函数。CIoU 是一种边界框回归定位损失函数,其考虑了目标真实框和预测框之间的重叠面积、中心点距离、尺度。从结果来看,在相同的测试集中 YOLOv3-CIoU 的识别精度更高,因此利用 YOLOv3-CIoU 算法生成的检测框更贴近于罹病木的边缘(图 3)。

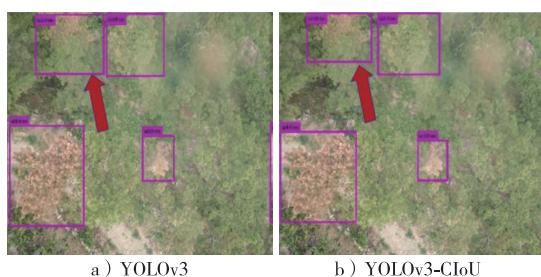


图 3 YOLOv3 和 YOLOv3-CIoU 检测结果对比<sup>[28]</sup>  
Fig. 3 Comparison of YOLOv3 and  
YOLOv3-CIoU test results

在罹病木检测过程中,采集和标注大量病树图像需要消耗大量的人力、物力和财力。对于罹病木来说,染病早期和中期不易被察觉,难以采集。在深度学习领域中,除了模型本身的优化,数据集的质量和数量也影响到模型最后的检测效果。因此对于松材线虫病害检测模型,扩增数据量有重要意义。主要有两种数据增强方法,一是通过传统的图像旋转、镜像、平移、修改对比度和亮度等方法对图像进行扩增。传统的数据增强技术虽然解决了数据集样本不足的问题,但数据质量差且样本多样性不足,容易造成过拟合,影响深度学习算法的分类性能<sup>[29]</sup>。生成对抗网络(generative adversarial networks, GAN)是 Goodfellow 等<sup>[30]</sup>在 2014 年提出的一种基于“二人博弈”思想的生成模型,其是在深度学习生成模型的基础上发展而来,由生成网络和判别网络两部分构成。利用 GAN 不仅能进行数据增强,还能提高图像分辨率<sup>[31-32]</sup>,如深度卷积生成对抗网络<sup>[33]</sup>(deep convolutional generative adversarial networks, DCGAN)增强训练集样本数量,减少过拟合,提高识别效果;使用条件生成对抗网络 (conditional generative adversarial network, CGAN)生成番茄叶子的合成图像提高了番茄病害的检测精度<sup>[34]</sup>。

Deng 等<sup>[35]</sup>提出了一种改进 Faster R-CNN 的

模型,首先通过旋转、翻转、对比度等方式对样本进行数据增强,由原始的 340 扩增为 1 700 个样本,然后将 Faster R-CNN<sup>[36]</sup>模型的特征提取网络 VGG16 替换为 Resnet101,将原来的多分类 softmax 损失函数改为单分类 sigmoid 损失函数,模型 mAP 值由 72.5% 提高为 80.2%,最后根据罹病木的冠幅大小修改区域生成网络中的锚框尺寸,模型的 mAP 值达到了 89.1%。为去除背景干扰,精确识别罹病木, Hu 等<sup>[37]</sup>提出一种基于 MobileNet 和 Faster R-CNN 算法的松材线虫病识别方法,其中 MobileNet 用于去除背景, Faster-RCNN 用于识别罹病木。同时使用 DCGAN 网络来增强训练样本数量,并比较了输入图像的大小和数量对研究结果的影响。

为避免单株罹病木信息的丢失、突出病害特征和抑制背景干扰,Qin 等<sup>[38]</sup>提出了一种基于多光谱图像的 SCANet(spatial-context-attention network) 图像分割网络,由空间信息保留模块、上下文信息模块以及注意力优化模块组成,同时使用多尺度分割法来提高样本的数量和多样性。

松材线虫病的早期监测是防治松材线虫病的关键。为了研究可行且准确的早期罹病木(松树树冠未出现明显颜色变化之前)检测方法,许多学者开始探索基于无人机的遥感影像对 PWD 早期检测的可行性。Wu 等<sup>[39]</sup>在不同时间获取同一地域的松树影像,并通过多时相观察来识别早期罹病木,发现砍伐罹病木后保留在原地可以降低松树感染数量,松材线虫可以在砍倒的松树体内存活。Yu 等<sup>[40]</sup>认为在实际的森林病虫害监测中需要一次确定罹病木的位置,然后采取相应的措施移除,而 Iordache 等<sup>[25]</sup>和 Wu 等<sup>[39]</sup>使用的多时相方法更适合于致病机制的研究。Yu 等<sup>[40]</sup>分别采用 Faster R-CNN 和 YOLOv4<sup>[41]</sup>两种目标检测算法对获取的多光谱影像进行不同感染阶段的罹病木识别,发现标记阔叶树可以提高罹病木在感染早期的识别准确性,防止将松树误判为阔叶树。

#### 1.4 基于人工设计特征和深度学习融合的松材线虫病监测方法

殷存军<sup>[42]</sup>将获取的数据集分为两组,一组为健康样本、松材线虫病样本和阴影样本,另一组为其他类样本,然后采用数据增广方式和 DCGAN 网络对松材线虫病样本进行扩增,并利用 Inceptionv3 网络去除无人机图像中的田地、裸土等复杂信息的干扰,然后根据罹病木、健康松树及阴影区域之间不同的颜色和纹理特征,使用一种基于多个单层决

策树组成的 AdaBoost 分类器对其进行分类,最后引入了形态学操作去除微小区域的背景干扰。图 4 中红色斑点代表检测结果,黄框代表正确检测的样本点,可以看出单独使用 Inceptionv3 网络将很多正样本误检为负样本,而 Inceptionv3 和 AdaBoost 网络的结合大大降低了模型的误检率。该方法与 Hu 等<sup>[37]</sup>提出的方法都使用了背景去除算法,从检测结果上来看,Hu 等<sup>[37]</sup>所用的方法虽然能将所有

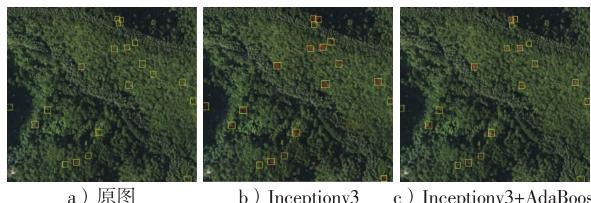


图 4 Inceptionv3 和 Inceptionv3+AdaBoost  
检测结果对比<sup>[42]</sup>

Fig. 4 Comparison of Inceptionv3 and Inceptionv3+  
AdaBoost detection results

的罹病木检测出来,但误检数量太多,导致人工砍伐罹病木的成本增加和工作效率降低。而殷存军<sup>[42]</sup>使用的方法可以在保证召回率的前提下,提高模型的精确率和  $F_1$  值。

对近几年使用深度学习方法在松材线虫病识别领域的相关研究进行总结,每个方法所用的数据集、CNN 架构、模型性能以及存在的缺点见表 2。主要是从准确率、精确率、召回率、平均精度和综合性能指标 F1-score 来衡量模型的性能。其中基于 YOLOv3-CIoU 的算法精确度最高,但模型的泛化能力不强,没有考虑其他复杂背景的影响;从单株罹病木的识别效果来看,SCANet 能够识别定位到单株罹病木的位置,抑制背景干扰;从模型的泛化能力和精确度来看,基于 Inceptionv3 和 AdaBoost 的算法优于其他算法,适用于复杂背景下检测罹病木,但基于 Faster R-CNN 和 YOLOv4 的算法能够识别不同感染阶段(中晚期)的罹病木。

表 2 深度学习方法在松材线虫病识别中的应用比较

Table 2 Application comparison of deep learning methods in pine wilt disease identification

数据集	CNN 架构	性能指标	缺点	文献
1 000 个罹病木样本,1 000 个其他地物样本	GoogLeNet, AlexNet	在纯林+平坦地形区域 AlexNet 的准确率和召回率最高,分别为 80% 和 70%;而在混合人工林+红色阔叶树区域 GoogLeNet 准确率和召回率最高,分别为 55% 和 36%。	该方法虽然考虑了复杂区域和红色阔叶树的影响,但罹病木漏检数量较多	[27]
836 个罹病木样本	YOLOv3-CIoU	精确率为 100%,准确率为 98.88%,召回率为 98.88%	模型的泛化能力不强,尤其是对分布密集、相互遮挡等复杂区域;没有考虑红色阔叶树和其他枯死树的影响	[28]
原有 340 个罹病木样本,数据增强后为 1 700 个	Faster R-CNN,	AP 为 89.0%,准确率为 89.1%,召回率为 90%		[35]
原有 25 个罹病木样本,数据增强后为 1 743 个	Faster R-CNN, DCGAN	精确率为 41.2%,召回率为 100%, $F_1$ -score 为 58.3%	误检数量较多,将很多未感染的松树检测为罹病木;背景信息没有去除完全;没有考虑红色阔叶树和其他枯死树的影响	[37]
原有 24 个罹病木样本,数据增强后为 696 个	Inceptionv3, AdaBoost DCGAN	精确率为 77.8%,召回率为 95.50%, $F_1$ -score 为 85.7%		[42]
训练样本包括 4 862 个罹病木样本	SCANet	OA 为 79.33%,精确率为 86%,召回率为 91%	考虑了单株罹病木的信息丢失问题,但多光谱数据来源成本相对较高	[38]
1 529 个罹病木样本,376 个阔叶树样本	Faster R-CNN, YOLOv4	Faster R-CNN 和 YOLOv4 的早期 AP 值为 48.88% 和 46.08%,中期 AP 值为 75.45% 和 71.3%,晚期 AP 值为 78.23% 和 74.55%	虽然考虑了阔叶树对罹病木识别的影响,但对阔叶树和早期罹病木的识别精度较低	[40]

衡量一个算法的好坏除了模型检测准确率,还需要考虑其检测速度。不同检测模型对应的平均单张图像检测速度不同,笔者对 5 种深度学习模型单张图像的检测效率进行了比较,即 AlexNet、GoogLeNet、MobileNetV2、Faster R-CNN、YOLOv3。其中数据集的所有图像都是在同一背景下获得的,图像分类的数据集包括 128 个健康松树样本和 128 个染病松树样本,图像目标检测的数据集包括 151 个染病松树样本。将数据集中的每一类划分

为 3 个子集,训练集、验证集和测试集的比例为 6:2:2。实验操作平台为 Ubuntu 20.04 计算机,Intel(R) Core(TM) i9-10900K CPU @ 3.70GHz, NVIDIA Corporation Device 2208, 使用 Pytorch 作为深度学习框架。在测试程序运行过程中,可以看出图像分类的 3 个检测模型中 AlexNet 的单张图像平均检测速度较快,而目标检测的两个模型中 YOLOv3 的检测速度较快(表 3)。

**表3 不同检测模型的单张图像平均检测时间**  
**Table 3 Average detection time per image for different detection models**

检测模型	单张图像平均检测时间/ms
AlexNet	1.36
GoogLeNet	6.79
MobileNetV2	4.85
Faster R-CNN	56.37
YOLOv3	25.93

## 2 松材线虫病罹病木监测难点及发展趋势

### 2.1 松材线虫病遥感监测中存在的问题

在林业病虫害识别分类方面,传统基于人工设计特征的检测方法虽然能一定程度提高人工目视判读的效率,但对于复杂背景的病害目标识别不够理想,尤其是在裸岩、裸土、阴影、其他枯死树等处理上,往往会因为颜色特征以及纹理特征与罹病木差异性小等问题产生误检错检的情况。由于森林数目种类多、变化大、罹病木和健康松树之间边界复杂以及无人机图像中罹病木尺寸小等原因,在监测罹病木的过程中存在漏判问题,如高度较低的罹病木以及相互遮挡的相邻罹病木。

缺乏大量、标注良好、高度可变的图像数据集是基于深度学习的松材线虫病识别模型的主要障碍。罹病木的检测受健康松树、建筑物、裸土、落叶松树、红色阔叶树、光照以及地形等影响,目前大多研究者的检测模型适应于特定区域的罹病木,对其他区域的罹病木检测泛化能力较弱,且目前研究的深度学习算法对早期罹病木的识别精度较低。

### 2.2 松材线虫病遥感监测发展趋势

松材线虫病的发生发展常受到许多环境因子的影响和制约,这些因子包括植物分布、土壤因素、林分基本特征、地形因素等。对于松材线虫病检测而言,单株罹病木的识别至关重要,而罹病木往往零星分布,要在无人机图像中将一株罹病木从复杂背景中自动区分开是一个世界难题。未来将融合光谱信息、时间信息、空间信息、上下文信息、激光雷达等来解决这一难题:光谱信息可以准确识别健康松树和罹病木<sup>[39,43]</sup>;其复杂背景的时间信息用来解决落叶树、棕色草本和植被稀疏区域季节性变色带来的干扰;空间信息用来减少低级信息的丢失(小目标);上下文信息用来扩大感受野,增强高级特征的提取(减少复杂背景的干扰)<sup>[38,44]</sup>;激光雷达能够获取树木的结构特征,准确地收集松树的三维信息并精确分割树冠,解决树冠的阴影和重叠造

成的光谱混淆问题<sup>[45]</sup>。

尽管光谱信息被广泛用于监测松材线虫病,但松材线虫病的早期识别很少有人研究。未来将会构建不同感染阶段的罹病木光谱库,综合分析不同染病程度、不同生长环境下罹病木的光谱特征,构建可以完备描述罹病木光学特征的冠层发射率高光谱模型,筛选早期罹病木的敏感波段,即最能表现其光谱特征且不易受其他因素影像的波段<sup>[9,11,40]</sup>。最后通过光谱、树冠、纹理、时空等多维信息进行有效融合,从复杂场景精准识别早期罹病木。

当前无人机获取遥感影像的技术已日趋成熟,国产高分辨率遥感卫星也正在逐步发展,北斗定位、物联网、云计算、人工智能、大数据等新技术不断涌现,多源遥感协同监测在应对重大突发事件中发挥着越来越重要的作用。为了实现单株罹病木的精细化管理,北斗高精度定位技术将融合卫星遥感影像、无人机影像实现罹病木的单株精准定位。

## 3 结语

回顾松材线虫病监测方法的发展历程,可以看到深度学习技术已经取代了传统人工设计特征方法。如果训练数据集足够大、足够精确,深度学习技术将更高精度、更高效地识别松材线虫病。而在缺乏大量数据集的情况下,数据增强已被证明可以改变模型的性能,包括传统的数据增强技术和GAN生成新的合成图像。从现有的文献中可以看出,大部分基于深度学习算法的监测方法都依赖于著名的CNN架构,如用于图像分类的AlexNet、GoogLeNet、Inceptionv3、MobileNet,可提取图像特征,具有良好的特征表达能力;常作用于其他视觉任务的基准模型,如用于图像检测任务的Faster R-CNN、YOLOX系列等算法,可利用其提取出来的特征识别目标。由近期相关报道也可以看出,从复杂的背景中分割出罹病木可以提高识别精度,而传统的手动裁剪感兴趣区域耗时耗力,因此使用背景去除和松材线虫罹病木分类的自动检测技术,对从复杂背景中提取松材线虫罹病木具有重大的意义。未来该领域的研究将结合高光谱高分辨率遥感卫星数据、无人机数据、北斗高精度定位以及物联网实时监测数据,达到“空天地网”一体化监测,从而准确识别早期罹病木,实现松材线虫病的精确检测与全过程动态监测。

### 参考文献(References):

- [1] 方兴. 研究无人机监测松材线虫病的应用实践[J]. 经济技术

- 协作信息, 2021(5): 81.
- FANG X. Research on the application practice of unmanned aerial vehicle monitoring pine wilt disease[J]. Economic and Technical Cooperation Information, 2021(5): 81.
- [2] 孙红, 周艳涛, 李晓冬, 等. 2020年全国主要林业有害生物发生情况及2021年发生趋势预测[J]. 中国森林病虫, 2021, 40(2): 45–48. DOI: 10.19688/j.cnki.issn1671-0886.20210004.
- SUN H, ZHOU Y T, LI X D, et al. The occurrence of major forestry pests nationwide in 2020 and the trend forecast in 2021[J]. Forest Pest and Disease, 2021, 40(2): 45–48.
- [3] YAMAGUCHI R, MATSUNAGA K, WATANABE A. Influence of temperature on pine wilt disease progression in *Pinus thunbergii* seedlings[J]. European Journal of Plant Pathology, 2020, 156(2): 581–590. DOI: 10.1007/s10658-019-01908-7.
- [4] 蒋敏, 黄斌, 余旭, 等. 松材线虫病的分布、危害及其防治对策[J]. 浙江林业科技, 2018, 38(6): 83–91. DOI: 10.3969/j.issn.1001-3776.2018.06.015.
- JIANG M, HUANG B, YU X, et al. Distribution, damage and control of pine wilt disease[J]. Journal of Zhejiang Forestry Science and Technology, 2018, 38(6): 83–91.
- [5] MOTA M M, VIEIRA P. Pine wilt disease: a worldwide threat to forest ecosystems[M]. Dordrecht: Springer Netherlands, 2008. DOI: 10.1007/978-1-4020-8455-3.
- [6] 国家林业和草原局. 国家林业和草原局公告(2022年第6号)(2022年松材线虫病疫区)[EB/OL]. (2022-03-18) [2022-05-24]. <http://www.forestry.gov.cn/main/3457/20220318/111403492220586.html>. National Forestry and Grassland Administration. Announcement of the National Forestry and Grassland Administration (No. 6 of 2022) (pine wood nematode epidemic area in 2022) [EB/OL]. (2022-03-18) [2022-05-24]. <http://www.forestry.gov.cn/main/3457/20220318/111403492220586.html>.
- [7] SANTOS C S S, VASCONCELOS M W. Identification of genes differentially expressed in *Pinus pinaster* and *Pinus pinea* after infection with the pine wood nematode[J]. European Journal of Plant Pathology, 2012, 132(3): 407–418. DOI: 10.1007/s10658-011-9886-z.
- [8] 徐华潮, 骆有庆, 张廷廷, 等. 松材线虫自然侵染后松树不同感病阶段针叶光谱特征变化[J]. 光谱学与光谱分析, 2011, 31(5): 1352–1356. DOI: 10.3964/j.issn.1000-0593(2011)05-1352-05.
- XU H C, LUO Y Q, ZHANG T T, et al. Changes of reflectance spectra of pine needles in different stage after being infected by pine wood nematode[J]. Spectroscopy and Spectral Analysis, 2011, 31(5): 1352–1356.
- [9] YU R, REN L L, LUO Y Q. Early detection of pine wilt disease in *Pinus tabuliformis* in north China using a field portable spectrometer and UAV-based hyperspectral imagery[J]. Forest Ecosystems, 2021, 8: 44. DOI: 10.1186/s40663-021-00328-6.
- [10] 张素兰, 覃菊, 唐晓东, 等. 松材线虫危害下马尾松光谱特征与估测模型研究[J]. 光谱学与光谱分析, 2019, 39(3): 865–872. DOI: 10.3964/j.issn.1000-0593(2019)03-0865-08.
- ZHANG S L, QIN J, TANG X D, et al. Spectral characteristics and evaluation model of *Pinus massoniana* suffering from *Bursaphelenchus xylophilus* disease[J]. Spectroscopy and Spectral Analysis, 2019, 39(3): 865–872.
- [11] KIM S R, LEE W K, LIM C H, et al. Hyperspectral analysis of pine wilt disease to determine an optimal detection index[J]. Forests, 2018, 9(3): 115. DOI: 10.3390/f9030115.
- [12] VOLLENWEIDER P, GÜNTHARDT-GOERG M S. Diagnosis of abiotic and biotic stress factors using the visible symptoms in foliage[J]. Environmental Pollution, 2005, 137(3): 455–465. DOI: 10.1016/j.envpol.2005.01.032.
- [13] 叶建仁. 松材线虫病在中国的流行现状、防治技术与对策分析[J]. 林业科学, 2019, 55(9): 1–10. DOI: 10.11707/j.1001-7488.20190901.
- YE J R. Epidemic status of pine wilt disease in China and its prevention and control techniques and counter measures[J]. Scientia Silvae Sinicae, 2019, 55(9): 1–10.
- [14] 吕传海, 潘厚平, 韩兵, 等. 松墨天牛生物学特性研究[J]. 安徽农业大学学报, 2000, 27(3): 243–246. DOI: 10.13610/j.cnki.1672-352x.2000.03.010.
- LYU C H, PU H P, HAN B, et al. Study on the biological characteristic of *Monochamus alternatus* Hope[J]. Journal of Anhui Agricultural University, 2000, 27(3): 243–246.
- [15] 朱宁波.《松材线虫病防治技术方案》和《松材线虫病疫区和疫木管理办法》重新修订发布[J]. 中国森林病虫, 2019, 38(1): 47–48. DOI: 10.3969/j.issn.1671-0886.2019.01.013.
- ZHU N B. The “Technical Plan for Prevention and Control of Pine Wood Nematode Disease” and the “Administrative Measures for Pine Wood Nematode Disease Areas and Diseased Woods” are re-released[J]. Forest Pest and Disease, 2019, 38(1): 47–48.
- [16] 曹忠. 低空无人机森林资源调查与监测应用现状与展望[J]. 林业建设, 2016(6): 1–5.
- CAO Z. Present situation and forecast on forest investigation and monitoring by unmanned aerial vehicle [J]. Forestry Construction, 2016(6): 1–5.
- [17] 朱晓敏. 浅谈无人机遥感技术在林业资源调查与监测中的应用[J]. 南方农业, 2020, 14(20): 76–77. DOI: 10.19415/j.cnki.1673-890x.2020.20.039.
- ZHU X M. Application of UAV remote sensing technology in forestry resources investigation and monitoring[J]. South China Agriculture, 2020, 14(20): 76–77.
- [18] NGUGI L C, ABELWAHAB M, ABO-ZAHHAD M. Recent advances in image processing techniques for automated leaf pest and disease recognition: a review[J]. Information Processing in Agriculture, 2021, 8(1): 27–51. DOI: 10.1016/j.inpa.2020.04.004.
- [19] 刘遐龄, 程多祥, 李涛, 等. 无人机遥感影像的松材线虫病危害木自动监测技术初探[J]. 中国森林病虫, 2018, 37(5): 16–21. DOI: 10.3969/j.issn.1671-0886.2018.05.004.
- LIU X L, CHENG D X, LI T, et al. Preliminary study on automatic monitoring trees infected by pine wood nematode with high-resolution images from unmanned aerial vehicle[J]. Forest Pest and Disease, 2018, 37(5): 16–21.
- [20] 陶欢, 李存军, 谢春春, 等. 基于HSV阈值法的无人机影像变色松树识别[J]. 南京林业大学学报(自然科学版), 2019, 43(3): 99–106. DOI: 10.3969/j.issn.1000-2006.201711035.
- TAO H, LI C J, XIE C C, et al. Recognition of red-attack pine trees from UAV imagery based on the HSV threshold method[J]. Journal of Nanjing Forestry University (Natural Sciences Edition), 2019, 43(3): 99–106.
- [21] SYIFA M, PARK S J, LEE C W. Detection of the pine wilt disease tree candidates for drone remote sensing using artificial intelligence techniques[J]. Engineering, 2020, 6(8): 919–926.

- DOI:10.1016/j.eng.2020.07.001.
- [22] 胡根生,张学敏,梁栋.基于WWSVDD多分类的遥感图像病害松树识别[J].北京邮电大学学报,2014,37(2):23-27. DOI:10.13190/j.jbupt.2014.02.006.
- HU G S, ZHANG X M, LIANG D. Infected pine recognition in remote sensing images using WWSVDD multi-classification [J]. Journal of Beijing University of Posts and Telecommunications, 2014, 37(2): 23-27.
- [23] YU R, LUO Y Q, ZHOU Q, et al. A machine learning algorithm to detect pine wilt disease using UAV-based hyperspectral imagery and LiDAR data at the tree level[J]. International Journal of Applied Earth Observation and Geoinformation, 2021, 101: 102363. DOI:10.1016/j.jag.2021.102363.
- [24] BREIMAN L. Random forests[J]. Machine Learning, 2001, 45 (1):5-32. DOI:10.1023/A:1010933404324.
- [25] IORDACHE M D, MANTAS V, BALTAZAR E, et al. A machine learning approach to detecting pine wilt disease using airborne spectral imagery[J]. Remote Sensing, 2020, 12(14): 2280. DOI:10.3390/rs12142280.
- [26] HAN Y C, WANG J. Application of convolutional neural networks in remote sensing image classification [C]//2019 2nd International Conference on Safety Produce Informatization (IICSP-PI). November 28-30, 2019, Chongqing, China. IEEE, 2019: 279-282. DOI:10.1109/IICSP148186.2019.9096058.
- [27] TAO H, LI C J, ZHAO D, et al. Deep learning-based dead pine tree detection from unmanned aerial vehicle images[J]. International Journal of Remote Sensing, 2020, 41(21): 8238-8255. DOI:10.1080/01431161.2020.1766145.
- [28] 李凤迪,申卫星,吴杰芳,等.基于YOLOv3-CIoU的松材线虫病树检测方法研究[J].山东农业大学学报(自然科学版),2021,52(2):224-233. DOI:10.3969/j.issn.1000-2324.2021.02.012.
- LI F D, SHEN W X, WU J F, et al. Study on the detection method for pinewood wilt disease tree based on YOLOv3-CIoU [J]. Journal of Shandong Agricultural University (Natural Science Edition), 2021, 52(2): 224-233.
- [29] 冯晓硕,沈樾,王冬琦.基于图像的数据增强方法发展现状综述[J].计算机科学与应用,2021,11(2):370-382. DOI:10.12677/csa.2021.112037.
- FENG X S, SHEN Y, WANG D Q. A survey on the development of image data augmentation[J]. Computer Science and Applications, 2021, 11(2): 370-382.
- [30] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[C]//Proceedings of the 27th International Conference on Neural Information Processing Systems. Montreal: ACM, 2014: 2672-2680.
- [31] ZHAO Y F, CHEN Z, GAO X, et al. Plant disease detection using generated leaves based on DoubleGAN[J]. IEEE/ACM Transactions on Computational Biology and Bioinformatics, 2022, 19(3): 1817-1826. DOI:10.1109/TCBB.2021.3056683.
- [32] 曹琨,吴飞,钱小瑞,等.基于GAN的无人机航拍图像重建[J].电子科技,2019,32(8):61-65. DOI:10.16180/j.cnki. issn1007-7820.2019.08.013.
- CAO K, WU F, QIAN X R, et al. Aerial image reconstruction of drone based on GAN[J]. Electronic Science and Technology, 2019, 32(8): 61-65.
- [33] RADFORD A, METZ L, CHINTALA S. Unsupervised representation learning with deep convolutional generative adversarial networks[EB/OL]. (2015-11-19) [2022-05-24]. <https://arxiv.org/abs/1511.06434>.
- [34] ABBAS A, JAIN S, GOUR M, et al. Tomato plant disease detection using transfer learning with C-GAN synthetic images[J]. Computers and Electronics in Agriculture, 2021, 187: 106279. DOI:10.1016/j.compag.2021.106279.
- [35] DENG X L, TONG Z J, LAN Y B, et al. Detection and location of dead trees with pine wilt disease based on deep learning and UAV remote sensing[J]. AgriEngineering, 2020, 2(2): 294-307. DOI:10.3390/agriengineering2020019.
- [36] REN S Q, HE K M, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39 (6): 1137 - 1149. DOI: 10.1109/TPAMI.2016.2577031.
- [37] HU G S, ZHU Y Q, WAN M Z, et al. Detection of diseased pine trees in unmanned aerial vehicle images by using deep convolutional neural networks[J]. Geocarto International, 2020: 1-20. DOI:10.1080/10106049.2020.1864025.
- [38] QIN J, WANG B, WU Y L, et al. Identifying pine wood nematode disease using UAV images and deep learning algorithms [J]. Remote Sensing, 2021, 13 (2): 162. DOI: 10.3390/rs13020162.
- [39] WU B Z, LIANG A J, ZHANG H F, et al. Application of conventional UAV-based high-throughput object detection to the early diagnosis of pine wilt disease by deep learning[J]. Forest Ecology and Management, 2021, 486: 118986. DOI:10.1016/j.foreco.2021.118986.
- [40] YU R, LUO Y Q, ZHOU Q, et al. Early detection of pine wilt disease using deep learning algorithms and UAV-based multispectral imagery[J]. Forest Ecology and Management, 2021, 497: 119493. DOI:10.1016/j.foreco.2021.119493.
- [41] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. YOLOv4: optimal speed and accuracy of object detection[EB/OL]. (2020-04-23) [2022-03-04]. <https://arxiv.org/abs/2004.10934>.
- [42] 殷存军.基于深度卷积网络和AdaBoost算法的无人机图像中病害松树识别[D].合肥:安徽大学,2020.
- YIN C J. Recognition of diseased *Pinus* trees in UAV images using deep convolutional network and AdaBoost classifier [D]. Hefei: Anhui University, 2020.
- [43] WU W B, ZHANG Z B, ZHENG L J, et al. Research progress on the early monitoring of pine wilt disease using hyperspectral techniques [J]. Sensors, 2020, 20 (13): 3729. DOI: 10.3390/s20133729.
- [44] ZHANG B Y, YE H C, LU W, et al. A spatiotemporal change detection method for monitoring pine wilt disease in a complex landscape using high-resolution remote sensing imagery[J]. Remote Sensing, 2021, 13(11): 2083. DOI:10.3390/rs13112083.
- [45] LIU L X, COOPS N C, AVEN N W, et al. Mapping urban tree species using integrated airborne hyperspectral and LiDAR remote sensing data[J]. Remote Sensing of Environment, 2017, 200: 170-182. DOI:10.1016/j.rse.2017.08.010.

(责任编辑 田亚玲)