

机器学习在植物病害识别研究中的应用^{*}

王聃¹, 柴秀娟^{1, 2}

(1. 中国农业科学院农业信息研究所, 北京市, 100081; 2. 农业农村部农业大数据重点实验室, 北京市, 100081)

摘要:植物病害识别是植物生长过程最重要也是最基本的环节,其既可以为高效除害提供最有力的依据,也可以减少一定的经济损失。随着信息技术的不断发展,在植物病害识别方面的研究工作已有一段历程,本文主要对机器学习技术在植物病害识别中的应用研究进行详细的综述。首先,通过调研植物病害问题的主要特征,明确植物病害识别研究中的识别任务;其次,阐述传统机器学习方法到深度学习的模式分类技术变迁,重点提出深度学习在植物病害识别中的应用优势;然后,调研机器学习在植物病害应用的相关研究文献,对文献所使用的模型、技术细节、数据来源、数据处理技术以及性能指标评价进行详细综述与对比,分析该领域研究存在的问题;最后,基于调研结果对植物病害识别的进一步研究展开讨论,同时对研究对象的特点与大规模数据集合的构建提出相关意见,在技术上提倡深度学习算法的使用,鼓励更加先进的模型尝试等建议。另外,还整理目前已经公开且可以下载使用的关于植物病害识别研究的数据库集合,为相关的研究提供便利。

关键词:机器学习;深度学习;植物病害识别

中图分类号:S431 TP391 文献标识码:A 文章编号:2095-5553(2019)09-0171-10

王聃, 柴秀娟. 机器学习在植物病害识别研究中的应用[J]. 中国农机化学报, 2019, 40(9): 171—180

Wang Dan, Chai Xiujuan. Application of machine learning in plant diseases recognition [J]. Journal of Chinese Agricultural Mechanization, 2019, 40(9): 171—180

0 引言

作物疾病与粮食安全息息相关^[1],植物病害的防治有助于作物生长,从而提高农作物的产量,保证农产品的质量,大大减少经济损失^[2]。提高除害工作效率的最基本前提是植物病害类别的准确识别。因此,对植物病害的早期发现与除害措施的及时实施对于农业生产来说是必不可少的^[3]。

传统的农作物相关识别任务,如病害识别、虫害识别^[4]、果实品质分级、产量预估等,通常是由经过专业培训或者有丰富经验的人来手工完成,但是任何由人类来完成的行为都会在某种程度上或多或少的受到主观因素的影响从而导致误差甚至错误的判断^[5]。而且,更现实的问题是,对于广阔的农作物区域来说,要完成全面系统的识别任务,仅仅依靠有限的人力资源是远远不够的^[6]。因此,一种可以自动识别植物病害的工具就显得尤为重要了。

图像分析是农业文化的一个重要研究领域,卫星、无人机以及智能手机的广泛使用为图像获取提供便

利^[7],也逐步突破对广域农作物图像采集的困难。同时,智能数据分析技术也正逐渐应用于图像识别、图像分类、异常检测^[8]等领域,这都为基于视觉的病害智能识别技术奠定基础。

机器学习是人工智能研究发展到一定阶段的必然产物。伴随着人类收集、存储、传输、处理数据的能力的飞速提升,机器学习技术也迅速成为很多交叉学科的重要技术支撑^[7]。在农业研究领域,由于农业信息化和精准农业的推广和实施,农业生产数据迅速增长并大量积累,这大大增加了农业发展对信息技术的需求^[9]。在植物病害研究中,传统的机器学习技术已经有了很好的应用效果,而深度学习^[10]更是将这项研究推进一大步,其强大的学习能力提高了神经网络的性能和精度,是最近流行的一种用于视觉图像分析的技术,深度学习技术^[11]在植物病害识别中的应用已成为本领域一个研究热点。

1 植物病害

作物在生长过程中,由于环境因素例如温度、湿

收稿日期:2019年3月5日 修回日期:2019年6月10日

*基金项目:国家自然科学基金(61472398)

第一作者:王聃,女,1993年生,甘肃白银人,硕士,研究实习员;研究方向为植物病虫害识别。E-mail: wangdan03@caas.cn

通讯作者:柴秀娟,女,1978年生,黑龙江木兰人,博士,研究员;研究方向为机器视觉、农业智能感知。E-mail: chaixiujuan@caas.cn

度、光照条件、作物营养过剩或欠缺以及作物品种等的影响,容易感染病害。按照引起植物病害的微生物种类将植物病害分为以下三类:一是病毒类病害,其表征是植物会出现斑点、环斑病甚至系统性坏死等;二是细菌类病害,其特点是植物会出现类似于叶斑病、枯萎病、萎蔫病、溃烂病、斑点病和结痂病等病害的相关症状;三是真菌类病害,这类病害常见的有炭疽病、锈病、根腐病和苗枯病等^[12]。植物病害的表征主要分为变色、坏死、腐烂、萎蔫、畸形五大类型。

经调研可知在植物病害识别这一研究中需要明确以下几点。

1) 病害感染会有不同严重程度的表现症状:由于病害存在生命周期,因此,在植物感染病害后会因感染的严重程度不同而表现出不同的症状。

2) 病害的感染位置不同:植物感染病害既可以表现在植物叶片上,也可以表现在作物的其他部位,例如枝干、果实等,因此正确的病害识别部位需要谨慎选择。

3) 多种植物病害共存的现象:对于不同的病害种类,作物感染后会表现出不同的颜色或者形状等,因此,在同一部位的多种病害同时存在的状况往往成为识别任务的干扰案例,从而产生识别误差。

以上所讨论到的作物病害特征为植物病害识别提供了参考,选择准确的识别目标是识别研究有效稳步前进的保障。

2 机器学习技术

机器学习技术是人工智能研究领域的重要成果,其研究的主要内容是学习算法,这是一种在计算机上从数据中产生模型的方法;学习算法可分为有监督学习、无监督学习和强化学习,主要用于识别、分类、量化及预测四个方向。在植物病害识别的研究中应用较为成功的几种传统机器学习方法主要包括贝叶斯分类器(Naïve Bayes Classifier)^[13-14]、支持向量机(SVM)^[15-18]、K-Means聚类算法^[19]以及人工神经网络(ANN)等。调研可知,人工神经网络在图像分类的研究中得到广泛应用^[20-22],并得到较为理想的结果。

近年来,随着可获取数据量的增加以及计算设备计算能力的大幅提高,深度卷积神经网络发展迅速,应用广泛。在深度学习工具中,最常用的是卷积神经网络(CNN)^[23-24]。这种神经网络比传统的前馈神经网络需要更少的人工神经元,特别适用于图像识别任务。如图 1 所示为 CNN 进行植物病害识别任务。

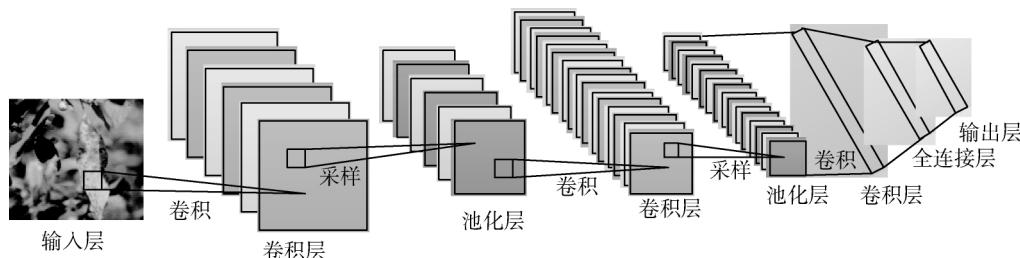


图 1 卷积神经网络用于植物病害识别

Fig. 1 Convolution neural network is used for plant disease recognition

CNN 复合多个“卷积层”与“池化层”对输入信号进行加工,然后在全连接层实现与输出目标之间的映射。每个卷积层都包含多个特征映射,每个特征映射是由多个神经元构成的“平面”,通过一个卷积滤波器提取输入的一种特征。采样层的作用是基于局部相关性原理进行采样,从而在减少数据量的同时保留有用信息。通过卷积层与采样层将原始图像映射成特征向量,最后通过一个全连接层与输出层连接完成识别任务。CNN 在训练中,无论是卷积层还是池化层,其每一组神经元都采用相同的连接权,也称为“权共享”,这样可以大幅减少训练参数的数目,从而节省训练开销,这个策略在卷积神经网络中发挥了重大作用。

目前常用的 CNN 经典模型主要有:CaffeNet^[25]、AlexNet^[26]、VGG^[27]、GoogleNet^[28]、Inception-ResNet^[29]等;每一种框架都有其各自的优势以及最佳的

使用场景。同时,也有很多基于深度学习的开发平台与工具,常用的有 TensorFlow、Caffe、PyTorch、Keras、Theano、TFLearn、Pylearn2 和 Matlab 深度学习工具箱。在研究中常常结合开发平台与学习架构优化深度学习。感兴趣的读者可以通过给出的文献对深度学习的理论知识与应用前景进行更加详细深入的了解^[30-35]。

针对本文的论点,卷积神经网络的学习能力对植物病害的识别和诊断具有重要的指导意义,近年来通过神经网络的应用使得植物病害的早期识别成为可能。

3 基于视觉的植物病害识别

机器学习技术在植物病害识别的应用宗旨是通过无损采集病害图像,利用图像处理技术对图像增强处理、分割病斑,提取特征并优化特征,然后使用模式识

别技术对病害类别进行诊断^[36]。对植物病害识别的训练和测试流程总结如图2所示。

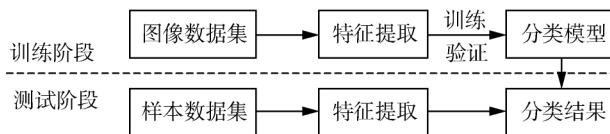


图2 识别模型训练流程图

Fig. 2 Training flow chart of recognition model

本节首先对用于植物病害识别研究的数据资源进行归纳总结,进而对机器学习在植物病害识别中的应用进行综述。

3.1 相关数据集

在基于视觉的植物病害识别研究中,都需要一定数量的图像数据进行试验。依本文来看,在不同的数据集上测试可以提高系统的鲁棒性,在相同的数据集上测试有助于不同技术的公正评价并促进技术的迅速发展。在研究者们的共同努力下,目前已经存在一定数据规模的植物病害数据集,本文通过检索归纳以下可使用的数据库便于进一步研究。PlantVillage 数据集是被使用次数较多的公开数据集^[37-41],由 David Hughes 和 Marcel Salathé 建立,旨在帮助农民大众了解在田间遇到的植物病虫害现象,并对相关的植物病虫害问题进行解答,数据集包含 87 848 张图像,主要有 58 类植物的病变及其健康的图像,如图3所示为该数据集中苹果疮痂病的图像示例,数据库中还有其他植物的疾病案例可供查阅。



图3 PlantVillage 数据集中苹果疮痂病的图像示例

Fig. 3 Sample images of apple scab venturia inaequalis in PlantVillage dataset

一些玉米相关数据集:许良凤^[42]等人与安徽省农科院合作,构建玉米叶部常见病害的数据库,数据库中共计 516 幅图片,包含玉米叶部圆斑病、小斑病、锈病、褐斑病、红叶病、弯孢霉叶斑病和纹枯病共 7 类病害。DECHANT^[43]等人采用佳能及索尼 a6000 相机采集了玉米植株图像,其中感染玉米枯萎病的图像有 1 017

张,健康植株图像有 768 张。田间玉米图像数据集^[44]是针对玉米北方叶枯病(NLB),通过手持相机、吊杆、小型无人机三种方式拍摄采集的三组数据,总计 18 222 张图像,并且由两位专家分别在图片上进行标注,共标注了带有 105 705 个 NLB 病变的图像,使其成为可公开获得的单个植物疾病标注的最大公开图像集。另外,还有其他类别的数据集,例如:LARESE^[45]等人使用的数据集是由 INTA (Instituto Nacional de Tecnología Agropecuaria, Oliveros, Argentina) 提供的关于黄豆、红豆和大豆的图片,总计 866 张图片,都是种子生长 12 d 后的第一片树叶的背面图像,采用标准平板扫描仪(惠普 Scanjet-G3110)获得,共采集标本 433 个:211 株大豆、136 株红豆、86 株白豆。Digipathos 数据集^[46]包含了近 5 万幅图像,显示了 21 种植物受到 171 种疾病的影响。Lu Y^[47]等使用佳能数字彩色相机自行采集了包含 10 种水稻疾病在内的数据集,总计 200 张图像,其中部分来自于《水稻病害图谱与防治技术》书中的扫描件。

表1列出了上述公开的数据资源及相应的下载网址。

表1 公开的植物病害数据集

Tab. 1 Released datasets on plant diseases and pests

名称	数据集来源
PlantVillage	https://plantvillage.psu.edu/
Digipathos	https://www.digipathos-rep.cnptia.embrapa.br/
黄瓜叶片图像	http://www.agronet.com.cn/
玉米枯萎病	http://bisque.iplantcollaborative.org
田间玉米图像	https://doi.org/10.1186/s13104-018-3548-6
水稻病害数据库	http://www.cnak.net/bccsjknew/Default.aspx
水稻病害图像数据库	http://bcch.ahnw.gov.cn/Right.aspx

3.2 传统机器学习方法的应用

对传统机器学习方法在植物病害识别研究中应用的调研总结中,主要对文献所使用的模型、技术细节、数据处理技术以及性能指标评价进行详细综述与对比,分析研究存在的问题。

以叶部常见病害为例,李冠林^[48]等提出了一种基于传统机器学习方法(K-means 聚类算法+支持向量机分类器)对小麦条锈病和叶锈病进行分类识别,平均识别率达到 98.34%,这是在病害种类少、数据样本小的情况下得到的理想结果,这也是传统机器学习方法在植物病害识别研究中应用的普遍特点。以下文章均以玉米叶部常见经典病害为研究对象,采用不同的

技术手段进行识别:

陈丽^[49]等对田间采集的玉米叶部病害图像经过预处理之后,针对较多的识别特征采用遗传算法进行特征优选以作为概率神经网络(PNN)的输入对锈病、灰斑病、小斑病、褐斑病和弯孢菌叶斑病进行识别,准确率为 90.4%;但是由于 PNN 分类器自身的弱点,在病害种类增加的情况下不仅会降低运算速度,也会出现准确率降低等问题。该试验的训练样本与测试样本规模为 250 幅。许良凤^[42]等同样是在大田开放环境下采集包含圆斑病、小斑病、锈病、褐斑病、红叶病、弯孢霉叶斑病和纹枯病共 7 类玉米叶部病害图像,分别对图像病害区域进行特征提取并构建相应的支持向量机分类器,文章重点在分类器识别部分提出一种基于自适应加权的多分类器融合的方法,平均识别率为 94.71%,很大地提高了单分类器的识别率;但是也因此加长了识别时间,且这种识别精度也未考虑复杂环境对数据集的影响;该试验的训练样本 270 幅,测试样本为 246 幅。张善文^[50]等以玉米叶部常见病害即包含锈病、弯孢菌叶斑病、褐斑病、大斑病和小斑病在内的图像数据集为试验数据库,针对识别前期叶片症状特征提取任务,提出局部判别映射(LDP)算法,试验结果得到高于 90% 的识别准确率,为基于叶片症状的作物病害识别研究得到最佳分类特征提供了理论依据。以上对于玉米叶部病害识别的研究中重点在病害特征提取方法上做出改进。另一方面,张建华^[51]等着力于识别技术的改进,构建了最优二叉树支持向量机模型对蜜柚叶部病害进行识别,在识别方法上对比了 BP 神经网络、一对一 SVM 与一对多 SVM 的训练时间与训练精度,得到改进的识别方法可以对蜜柚叶部感染黄斑病、炭疽病、疮痂病、煤烟病单一病害时识别率达到 94.16%;但是该试验对象是叶部病害中晚期阶段,且叶片均是感染单一病害的症状,该试验的训练样本 240 幅,测试样本 120 幅。

同时,多特征融合技术的发展,为植物病害识别在利用多个病害特征融合方面实现准确识别奠定了技术基础。在特征提取方面,Zhang S 等^[52]利用稀疏表示模型(SR)对病害叶片图像进行特征提取,采用 K-means 对黄瓜病害叶片图像进行分割,能有效识别 7 种主要黄瓜病害,总识别率为 85.7%。改进之处是该方法同时基于形状特征和颜色特征进行识别,且对于分类特征赋予不同的权值,该方法同样是基于小型叶片数据库,共使用 7 种病害的 420 幅图片。在识别方法方面,王志彬^[53]充分利用 BP 神经网络、SVM、Bagging、AdaBoost 算法的优势,针对每一病变图像动态选择出性能最优的分类器或者分类器组合对黄瓜白粉

病、灰霉病、霜霉病实现识别效果最佳的分类方法,即采用基于动态集成的方法对黄瓜叶部病害进行识别,但是这种方法存在耗时较长的问题,样本集为 2 443 幅。

综合以上文献调研,得到传统机器学习方法在病害识别中存在以下劣势。

1) 虽然这些研究结果显示出了很高的准确率,但是他们大多是在实验室条件下完成的测试,而不是在现场田埂作业中获得的实时测试结果。

2) 以往通过机器学习对病害进行分类的研究大多是对单一植物的疾病展开研究的,只是针对这类植物的一种病害进行检测,数据规模所涵盖的病害种类也有限,即样本数较少。

3) 以往在机器学习用于现实任务时,描述样本的特征通常需要人类专家来设计,也就是“特征工程”^[54]。众所周知,特征的好坏对泛化性能有至关重要的影响,而人类专家设计出好特征并非易事。

3.3 深度学习的应用

自 2015 年起,深度学习在植物病害识别中的应用研究逐渐深入。如前文所述,深度学习工具中使用最广泛的是卷积神经网络^[55],卷积神经网络相较于传统神经网络的优势是大大减少了结构元件的数量。深度学习可以理解为“特征学习”,它是通过多层处理,逐渐将初始的“低层”特征表示转化为“高层”特征表示后,用“简单模型”完成复杂的分类等任务,并且在视觉、语音、自然语言等应用领域迅速发展,存在以 Tensorflow 和 Caffe^[56]为引领的较为成熟的深度学习训练框架,在图像识别方面占据很强的优势。下面即对 CNN 相关的病害识别工作进行简单介绍。

Mohanty S P^[57]利用 CNN 对 54 306 张包含健康与病害植物叶子的图像进行训练,得到一个可以自动诊断植物疾病的系统,研究中采用了 AlexNet 和 GoogLeNet 两个框架,并且采用迁移学习方法处理数据集、减少过拟合问题,该系统表现出的检测精度是 99.35%,但是该精度在与训练集不同的条件下拍摄的图像上进行测试时性能会有所降低。深度学习在植物病害严重程度检测中也发挥重要作用。Wang G 等^[58]通过深度学习训练得到基于图像的植物疾病严重程度自动评估系统,图像来自 PlantVillage 数据集中的苹果黑腐病图像集,对比了 VGG16、VGG19、Inception-v3 和 ResNet50 模型的训练精度,得到 VGG16 模型在测试集上的精度达到 90.4%。

我们知道卷积神经网络(CNN)通常需要大量的样本进行训练;然而,在许多实际应用中,收集模型所需要的训练数据较为困难,且成本很高^[59]。因此,在

数据扩充方面的研究就显得尤为重要,以往研究中,很多研究人员在基于有限的数据集合的条件下结合深度学习与迁移学习,同时使用图像处理单元(GPU),开发了植物病害识别与分类的工具^[60]。Svdjan S^[61]提出了关于深度学习模型的评估方法,采用深度学习对14种不同类型的植物疾病进行识别,包含13类病害和健康的植物叶片图像,结合迁移学习方法得到数据集规模为训练集合30880幅图像,训练集合为2589幅图像;训练基于Caffe深度学习框,平均准确率达到96.3%。同样地,Liu B等^[62]通过旋转、镜像、加高斯噪声、亮度调整、对比度调整等操作,增强训练数据集,使得训练集的大小增加了12倍,减少了过拟合问题。

当然,除了数据量的扩充,在学习算法方面的改进对于研究结果的提高也是至关重要的。研究者将深度学习架构(深度残差网络、VGG Net等)与目标检测模型(Faster R-CNN、R-FCN、SSD等)结合使用来提高识别鲁棒性与精度等。Dyrmann M^[63]利用深度学习对植物进行分类,研究者通过自助搭建一种卷积神经网络,可以在彩色图像中识别植物物种,模型是在10413张包含有22种杂草和作物品种的数据集上进行训练和测试后建立起来的,平均分类准确率为86.2%。经过试验数据分析得出,该试验数据集包含物种种类较多,而某些单个数据集数量不充足导致准确率下降。Too E C等^[64]积极尝试更深度的网络构架,使用了PlantVillage数据集中的图像,形成的数据规模为:训练集样本34727个,验证集样本8702个,测试集样本10876个,通过对比试验验证了DenseNets相较于VGG和ResNet来说,需要更少的参数和合理的计算时间就可以达到最先进的性能,实现了99.75%的测试准确率,高于其他结构的性能。

综合文献可以看到,以上工作虽然在研究结果上看起来非常可观,不过,调研中看到大多数研究结论都是基于以下两点进行考虑的:①大部分的研究在数据集扩充方面大多采用了迁移学习的方法;除此之外,更多的扩充数据集合的方法有待开发与尝试;同时,扩充数据集合最基本的方法应是采集更全面更大容量的数据样本。②使用了经典的卷积神经网络架构;而网络架构的改进以及开发更加先进的网络架构也是研究者们努力的方向。

4 相关讨论

纵观机器学习在植物病害识别中的应用历程,尽管传统识别方法在特定条件下可以达到较好的识别准确率,但是,随着更高要求的提出,比如识别方法的现场应用精度、应用广泛性以及识别系统的鲁棒性等,使

得在这方面的研究需要更丰富的数据资源和更强大的学习算法。在本文看来,在不同的数据集上测试可以提高系统的鲁棒性,在相同的数据集上测试有助于不同技术的公正评价并促进技术的迅速发展。在3.1节列出的相关数据库中图像都是可见光图像,数据来源更加丰富、数据量更加庞大的数据集合构建还需研究者的共同努力。

Lecun Y^[65]等人提到在基于机器学习的很多典型应用案例都有一种使用深度学习算法代替传统方法的趋势。深度学习在图像识别方面的优势亦使其成为研究植物病害识别方法的必然趋势。深度学习与传统模式识别方法最大的不同有两点,其一是在特征提取时深度学习采用自动学习特征的方式,即从大数据中自动学习特征,而不是采用手工设计的提取方式。这样克服了手工提取特征的耗时与人员先验知识限制的缺点,提高了学习速度。其二是在特征提取与分类器的联合协作方面,在传统方法中,二者是分开阶段组合完成分类任务,而在深度学习中,二者是结合一起优化完成分类任务的。如图4所示,在模式识别任务中,从传统方法到深度学习的技术变迁。

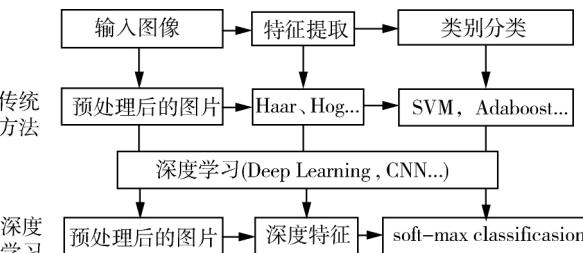


图4 从传统方法到深度学习的模式分类技术变迁

Fig. 4 Change of pattern classification technology from traditional methods to deep learning

4.1 对前期任务的讨论

将深度学习应用于植物病害识别已是一种必然趋势,随着对识别要求的不断提高,比如更高的识别精度、更短的计算时间、更好的系统鲁棒性、更强的泛化能力等,表明在这一领域目前的研究成熟度距离实际应用还有一段路程。因此,本文将对研究存在的挑战进行分析,并提出应对措施。

从研究对象本身面临的挑战出发,由于植物病害可能存在并发症,即同时感染多种病害以及病害、害虫的同时存在,这都会给识别带来困难,将直接导致原有识别系统的错误率上升。此外,由于植物对不同的病害感染可能会表现出相同的症状,仅凭这样的外观特征无法保证得到正确的判别结果。由于作物在不同的生长阶段对一种病害感染会表现出不同的特征,这也阻碍了系统作出正确的判断^[55]。因此,面对以上诸多难点,研究者必须在采集数据时,必须尽量全面,尽可

能的覆盖植物在不同病害时期、不同病害条件下的各种图像,以确保模型训练及识别系统的准确性。对视觉无法有效区分的极端情况,需要从算法上融合先验知识共同进行决策。

从数据集的构建角度出发,综合试验结果的调研可以看出,以往研究往往会在相似数据集的测试中表现出良好的性能,但是在现场实际环境中使用时就会受到其他因素的影响,而这些因素在试验研究中并没有提前训练,这样终会限制识别系统在实际农作区域的使用。Feventiens K P^[40] 分别将用现场条件所得数据集和实验室条件下所得数据集训练的网络应用于实际现场图像的识别,发现前者准确率高出后者 35%。因此,数据集构建过程中应尽量多的包含不同角度、不同光照条件、不同背景变化的图像以确保系统的鲁棒性。还需要注意的是病害信息覆盖性问题,植物叶片的症状和体征可能由多种原因引起,比如感染疾病、营养不良、害虫、机械损伤、冷热损伤等,而在建立识别系统时只是列入了较为常见的植物病害,并未全部覆盖所有可能引起病变的原因,当在现实环境条件下使用病害识别工具时,由于其在系统训练子集中找到的是最接近的结果,从而导致诊断的错误。

从数据处理和分析角度出发,基于深度学习的病害识别已是研究者们公认的热点。首先,深度学习的训练需要大量的数据作为基础,不过迁移学习与数据扩充技术的使用可以在一定程度上缓解数据量不足的问题。其次,是图像背景的问题,虽然 Barbedo J G A^[55] 在研究中证明去除图像背景可以将识别准确率提高 3 个百分点,但是由于去除背景的工作量大且需要专业人士完成,这一步骤往往在应用中很难实现,但研究者针对复杂背景,可以考虑融合深度图像数据或设计新的网络结构来学习得到表达能力更强的深度特征。最后,对于数据标注这一必不可少的过程,也存在两方面挑战:一方面是严格数据标注的过程缓慢且代价大;另一方面是采集环境的复杂性会引起标注的不确定性。显然,完全准确标注的数据是很难保证的,不过,Becker A J^[66] 在研究中验证得出,在错误标注的样本数量不是很高的情况下,深度卷积网络可以保持较高的可靠性。当然,在标注的后期,也可以先尝试使用一部分训练样本训练得到初始模型,结合初始模型给出的标签进行半自动的数据标注。另一方面,在不能保证数据标签正确性的时候,可考虑结合弱监督学习策略进行模型的训练。

4.2 对学习算法的讨论

卷积神经网络从 90 年代的 LeNet 开始,经历了

AlexNet、ZFNet、VGG、GoogLeNet、ResNet 和 DenseNet 等,网络越来越深,架构越来越复杂,解决反向传播时梯度消失的方法也越来越巧妙。因此,将深度学习在植物病害研究中进行应用时有望可以使用更加先进的网络来实现。同时,除了使用经典的结构以外还要结合植物病害识别问题的特殊性运用并探索更加先进的模型和方法来解决复杂的问题,正如深度学习在农业其他领域的应用一样:对番茄果实数量的估算应用改良后的 Inception-ResNet CNN 架构^[67];对橘子或苹果果实数量估算系统采用了适用于斑点检测和计数的 CNN 和线性回归方法^[68] 等。Lee S H 等^[59] 提出使用叶片脉序结构来区分不同植物类别的方法,并通过试验证明其方法的识别率为 99.6%。目前应用在植物病害识别研究中较少的 Faster Region-based CNN 与 DetectNet CNN 等方法也是很有前景的研究方向。此外,从病害识别的本质和特殊性出发,相关研究人员也可以在图像预处理、数据扩充、深度特征学习、损失函数设计等不同的阶段,进行算法的创新和设计,以促进病害识别研究的技术发展,使其可以在实际场景中尽快得到大规模应用。最后,本文建议适当的参数微调来提高识别精度,正如 Tang J L 等^[69] 将 K-Means 无监督特征学习作为训练前的过程,取代了传统 CNN 参数的随机初始化权值,使参数在优化前得到更合理的值,从而将杂草识别精度提高了 1.82%。

4.3 对后期提升的讨论

在研究中,为了得到更加鲁棒的植物病害识别系统,可以利用不同来源的数据共同训练模型,这样可能对提高系统的鲁棒性和泛化能力有一定的帮助。此外,如果新的应用场景与训练数据差异较大,也可以通过采集新场景下的少量数据,通过迁移学习对原始模型进行自适应更新,以对系统性能进行改善。最后,对于研究者们来说,更全面更具有挑战的数据集是一大需求,也是共同努力的目标。

5 结论

本文综述了机器学习技术在植物病害识别中的应用研究,总的技术路线是对植物病害图像进行无损采集,经过数据预处理,提取图像特征表示,再通过模式识别技术对病害进行识别判断。目前,深度学习算法已逐步被应用到各个不同行业领域,农业是该算法应用的主要方向之一。

首先,本文对传统机器学习技术在植物病害识别中的应用相关研究进行分析对比,由技术可靠性引起论述,接着以玉米叶部常见病害为典型病害进行技术演变分析,然后分别以“研究特征提取”改进与“识别技

术”改进两个方面进行综述该研究问题应用技术的改进发展，并且通过分析以上文献存在的劣势与问题总结传统机器学习方法在植物病害识别中存在的劣势。其次，调研深度学习在植物病害识别中的应用研究，从目前已达到的研究水平，数据集扩充和学习算法改进的研究角度，提出深度学习在该研究领域应用的必然趋势；本文对传统方法和深度学习方法在模式识别任务中的技术变迁进行总结提炼核心技术、凝练深度学习技术理念、梳理深度学习技术应用模型与开发平台、总结提炼模式识别训练流程图。最后，依本文来看，在不同的数据集上测试可以提高系统的鲁棒性，在相同的数据集上测试有助于不同技术的公正评价并促进技术的迅速发展。同时，本文对已有研究取得的进步与存在的问题进行总结，针对提高识别系统精度、提高系统泛化性能以及构建大规模数据集合等方面的问题，通过调研提出相关改进意见，为其进一步的研究提供参考。

深度学习的优势越来越鼓舞人心，我们的目标是激发更多的研究人员加入到深度学习的研究队伍中来，将其应用于更加广泛的农业问题，促进农业可持续发展，促使更智能、更安全的农业生产。

参 考 文 献

- [1] 滕葳,柳琪,郭栋梁. 我国蔬菜病虫害的基本概况及对蔬菜质量安全的影响分析[J]. 食品研究与开发, 2003, 24(5): 3—5.
- [2] 邱白晶,王天波,李娟娟. 黄瓜蚜虫的图像识别与计数方法[J]. 农业机械学报, 2010, 41(8): 151—155.
Qiu Baijing, Wang Tianbo, Li Juanjuan, et al. Image recognition and counting for glasshouse aphid gossypii [J]. Transactions of the Chinese Society for Agricultural Machinery, 2010, 41(8): 151—155.
- [3] 周志艳,罗锡文,张扬. 农作物虫害的机器检测与监测技术研究进展[J]. 昆虫学报, 2010, 53(1): 98—109.
Zhou Zhiyan, Luo Xiwen, Zhang Yang, et al. Machine-based technologies for detecting and monitoring insect pests of crops: A review [J]. Acta Entomologica Sinica, 2010, 53(1): 98—109.
- [4] 陈雪艳,李理,范晓静,等. 基于神经网络和证据理论的农田虫害预测算法[J]. 中国农机化学报, 2019, 40(2): 151—156.
Chen Xueyan, Li Li, Fan Xiaojing, et al. Farmland and pest prediction algorithm based on neural network and evidence theory [J]. Journal of Chinese Agricultural Mechanization, 2019, 40(2): 151—156.
- [5] Bock C H, Poole G H, Parker P E. Plant disease severity estimated visually, by digital photography and image analysis, and by hyperspectral imaging [J]. Critical Reviews in Plant Sciences, 2010, 29(2): 59—107.
- [6] Garciaab J. Digital image processing techniques for detecting, quantifying and classifying plant diseases [J]. Springerplus, 2013, 2(1): 660.
- [7] 鲁恒,付萧,贺一楠. 基于迁移学习的无人机影像耕地信息提取方法[J]. 农业机械学报, 2015, 46(12): 274—279.
Lu Heng, Fu Xiao, He Yinan. Cultivated land information extraction from high resolution UAV images based on transfer learning [J]. Transactions of the Chinese Society for Agricultural Machinery, 2015, 46(12): 274—279.
- [8] 张云,许江淳,王志伟,等. 基于机器视觉的棉花异性纤维检测技术优化研究[J]. 中国农机化学报, 2018, 39(9): 61—65.
Zhang Yun, Xu Jiangchun, Wang Zhiwei, et al. Optimization of cotton heterosexuality detection technology based on machine vision [J]. Journal of Chinese Agricultural Mechanization, 2018, 39(9): 61—65.
- [9] 何世明. 基于机器学习及群智能寻优算法的化工故障诊断建模优化研究[D]. 杭州: 浙江大学, 2018.
He Shiming. Modeling and optimization of chemical fault diagnosis based on machine learning and swarm intelligent optimization algorithm [D]. Hangzhou: Zhejiang University, 2018.
- [10] 赵东. 基于群智能优化的机器学习方法研究及应用[D]. 长春: 吉林大学, 2017.
Zhao Dong. Research and application of machine learning method based on swarm intelligence optimization [D]. Changchun: Jilin University 2017.
- [11] 孙志军,薛磊,许阳明,等. 深度学习研究综述[J]. 计算机应用研究, 2012, 29(8): 2806—2810.
Sun Zhijun, Xue Lei, Xu Yangming, et al. Overview of deep learning [J]. Application Research of Computers, 2012, 29(8): 2806—2810.
- [12] Foster G D, Taylor S C. Plant virology protocols [J]. Methods in Molecular Biology, 2015, 451.
- [13] 董立岩,苑森淼,刘光远,等. 基于贝叶斯分类器的图像分类[J]. 吉林大学学报(理学版), 2007, 45(2): 249—253.
Dong Liyan, Yuan Semiao, Liu Guangyuan, et al. Image classification based on bayesian classifier [J]. Journal of Jilin University(Science Edition), 2007, 45(2): 249—253.
- [14] 杨昕薇,谭峰. 基于贝叶斯分类器的水稻病害识别处理的研究[J]. 黑龙江八一农垦大学学报, 2012, 24(3): 64—67.
Yang Xinwei, Tan Feng. Research of treatment of the rice disease recognition based on bayes classifier [J]. Journal of Heilongjiang Bayi Agricultural University, 2012, 24(3): 64—67.
- [15] 刘彤,武海巍,曹忠. 基于支持向量机的水稻净光合速率预测模型[J]. 中国农机化学报, 2016, 37(9): 151—153.
Liu Tong, Wu Haiwei, Cao Zhong. Prediction model on net photosynthetic rate of rice based on support vector machine [J]. Journal of Chinese Agricultural Mechanization,

- 2016, 37(9): 151—153.
- [16] 刘媛, 冯全. 葡萄病害的计算机识别方法[J]. 中国农机学报, 2017, 38(4): 99—104.
Liu Yuan, Feng Quan. Identification method of grape disease based on computer technology [J]. Journal of Chinese Agricultural Mechanization, 2017, 38(4): 99—104.
- [17] 张学工. 关于统计学习理论与支持向量机[J]. 自动化学报, 2000, 26(1): 32—42.
Zhang Xuegong. Introduction to statistical learning theory and support vector machines [J]. Acta Automatica Sinica, 2000, 26(1): 32—42.
- [18] 丁世飞, 齐丙娟, 谭红艳. 支持向量机理论与算法研究综述[J]. 电子科技大学学报, 2011, 40(1): 2—10.
Ding Shifei, Qi Bingjuan, Tan Hongyan. An overview on theory and algorithm of support vector machines [J]. Journal of University of Electronic Science & Technology of China, 2011, 40(1): 2—10.
- [19] 黄韬, 刘胜辉, 谭艳娜. 基于 k-means 聚类算法的研究[J]. 计算机技术与发展, 2011, 21(7): 54—57.
Huang Tao, Liu Shenghui, Tan Yanna. Research of clustering algorithm based on k-means [J]. Computer Technology & Development, 2011, 21(7): 54—57.
- [20] 杨治明, 王晓蓉, 彭军. BP 人工神经网络在图像分割中的应用[J]. 计算机科学, 2007, 34(3): 234—236.
Yang Zhiming, Wang Xiaorong, Peng Jun. The application of BP neural networks in image segmentation [J]. Computer Science, 2007, 34(3): 234—236.
- [21] Zeiler M D, Fergus R. Visualizing and understanding convolutional networks [J]. 2013, 8689: 818—833.
- [22] He K, Zhang X, Ren S. Deep residual learning for image recognition [J]. 2015: 770—778.
- [23] Ferentinos K P. Deep learning models for plant disease detection and diagnosis [J]. Computers & Electronics in Agriculture, 2018, 145: 311—318.
- [24] Lowe A, Harrison N, French A P. Hyperspectral image analysis techniques for the detection and classification of the early onset of plant disease and stress [J]. Plant Methods, 2017, 13(1): 80.
- [25] Jia Y, Shelhamer E, Donahue J. Caffe: Convolutional architecture for fast feature embedding [C]. Acm International Conference on Multimedia, 2014: 675—678.
- [26] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks [C]. International Conference on Neural Information Processing Systems, Curran Associates Inc, 2012: 1097—1105.
- [27] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition [J]. Computer Science, 2014.
- [28] Szegedy C, Liu W, Jia Y. Going deeper with convolutions [J]. 2014: 1—9.
- [29] Szegedy C, Ioffe S, Vanhoucke V. Inception-v4, Inception-resnet and the impact of residual connections on learning [J]. 2016.
- [30] Schmidhuber J. Deep learning in neural networks: an overview [J]. Neural Networks, 2015, 61: 85—117.
- [31] Deng L, Yu D. Deep learning: methods and applications [J]. Foundations & Trends in Signal Processing, 2014, 7(3): 197—387.
- [32] Wan J, Wang D, Hoi S C H. Deep learning for content-based image retrieval: A comprehensive study [C]. ACM International Conference on Multimedia, ACM, 2014: 157—166.
- [33] Najafabadi M, Villanustre F, Khoshgoftaar T M. Deep learning applications and challenges in big data analytics [J]. Journal of Big Data, 2015, 2(1): 1.
- [34] Canziani A, Paszke A, Culurciello E. An analysis of deep neural network models for practical applications [J]. 2016.
- [35] Bahrampour S, Ramakrishnan N, Schott L. Comparative study of caffe, neon, theano, and torch for deep learning [J]. Computer Science, 2015.
- [36] 濮永仙. 计算机视觉在作物病害诊断中的研究进展[J]. 智能计算机与应用, 2015(2): 68—72.
Pu Yongxian. The research development of computer vision in the plant disease diagnosis [J]. Intelligent Computer & Applications, 2015(2): 68—72.
- [37] Amara J, Bouaziz B, Algergawy A. A deep learning-based approach for banana leaf diseases classification [C]. Datenbanksysteme Für Business, Technologie Und Web, 2017: 79—88.
- [38] Brahim M, Boukhalfa K, Moussaoui A. Deep learning for tomato diseases: classification and symptoms visualization [J]. Applied Artificial Intelligence, 2017: 1—17.
- [39] Cruz A C, Luvisi A, De B L. X-FIDO: an effective application for detecting olive quick decline syndrome with deep learning and data fusion [J]. Frontiers in Plant Science, 2017, 8: 1741.
- [40] Ferentinos K P. Deep learning models for plant disease detection and diagnosis [J]. Computers & Electronics in Agriculture, 2018, 145: 311—318.
- [41] Mohanty S P, Hughes D P, Salathé M. Using deep learning for image-based plant disease detection [J]. Frontiers in Plant Science, 2016, 7.
- [42] 许良凤, 徐小兵, 胡敏, 等. 基于多分类器融合的玉米叶部病害识别[J]. 农业工程学报, 2015, 31(14): 194—201.
Xu Liangfeng, Xu Xiaobing, Hu Min, et al. Corn leaf disease identification based on multiple classifiers fusion [J]. Transactions of the Chinese Society of Agricultural Engineering, 2015, 31(14): 194—201.
- [43] Dechant C, Wiesnerhanks T, Chen S. Automated identification of northern leaf blight-infected maize plants from field imagery using deep learning [J]. Phytopathology, 2017, 107(11): 1426—1432.
- [44] Wiesner-hanks T, Stewart E L, Kaczmar N. Image set for deep learning: field images of maize annotated with disease

- symptoms [J]. Bmc Research Notes, 2018, 11(1): 440.
- [45] Larese M G, Namias R, Craviotto R M. Automatic classification of legumes using leaf vein image features [J]. Pattern Recognition, 2014, 47(1): 158—168.
- [46] Barbedo J G A. Factors influencing the use of deep learning for plant disease recognition [J]. Biosystems Engineering, 2018, 172: 84—91.
- [47] Lu Y, Yi S, Zeng N. Identification of rice diseases using deep convolutional neural networks [J]. Neurocomputing, 2017, 267.
- [48] 李冠林, 马占鸿, 王海光. 基于支持向量机的小麦条锈病和叶锈病图像识别[J]. 中国农业大学学报, 2012, 17(2): 72—79.
Li Guanlin, Ma Zhanhong, Wang Haiguang. Image recognition of wheat stripe rust and wheat leaf rust, based on support vector machine [J]. Journal of China Agricultural University, 2012, 17(2): 72—79.
- [49] 陈丽, 王兰英. 概率神经网络在玉米叶部病害识别中的应用[J]. 农机化研究, 2011, 48(6): 145—148.
Chen Li, Wang Lanying. Research on application of probability neural network in maize leaf disease identification [J]. Journal of Agricultural Mechanization Research, 2011, 48(6): 145—148.
- [50] 张善文, 张传雷. 基于局部判别映射算法的玉米病害识别方法[J]. 农业工程学报, 2014, 30(11): 167—172.
Zhang Shanwen, Zhang Chuanlei. Maize disease recognition based on local discriminant algorithm [J]. Transactions of the Chinese Society of Agricultural Engineering, 2014, 30(11): 167—172.
- [51] 张建华, 孔繁涛, 李哲敏. 基于最优二叉树支持向量机的蜜柚叶部病害识别[J]. 农业工程学报, 2014, 30(19): 222—231.
Zhang Jianhua, Kong Fantao, Li Zhemin. Recognition of honey pomelo leaf diseases based on optimal binary tree-support vector machine [J]. Transactions of the Chinese Society of Agricultural Engineering, 2014, 30(19): 222—231.
- [52] Zhang S, You Z. Leaf image based cucumber disease recognition using sparse representation classification [J]. Computers & Electronics in Agriculture, 2017, 134(C): 135—141.
- [53] 王志彬, 王开义, 王书锋. 基于动态集成的黄瓜叶部病害识别方法[J]. 农业机械学报, 2017, 48(9): 46—52.
Wang Zhibin, Wang Kaiyi, Wang Shufeng. Recognition method of cucumber leaf diseases with dynamic ensemble learning [J]. Transactions of the Chinese Society for Agricultural Machinery, 2017, 48(9): 46—52.
- [54] 周志华. 机器学习: Machine learning [M]. 北京: 清华大学出版社, 2016.
- [55] Barbedo J G A. A review on the main challenges in automatic plant disease identification based on visible range im-
- ages [J]. Biosystems Engineering, 2016, 144: 52—60.
- [56] 蒋丰千, 李旸, 余大为, 等. 基于 Caffe 的生姜病害识别系统研究与设计[J]. 中国农机化学报, 2019, 40(1): 126—131.
Jiang Fengqian, Li Yang, Yu Dawei, et al. Design and experiment of tobacco leaf grade recognition system based on Caffe [J]. Journal of Chinese Agricultural Mechanization, 2019, 40(1): 126—131.
- [57] Mohanty S P, Hughes D P, Salathé M. Using deep learning for image-based plant disease detection [J]. Frontiers in Plant Science, 2016, 7.
- [58] Wang G, Sun Y, Wang J. Automatic image-based plant disease severity estimation using deep learning [J]. Computational intelligence and neuroscience, 2017, 2917536.
- [59] Lee S H, Chan C S, Wilkin P, et al. Deep-plant: Plant identification with convolutional neural networks [C]. IEEE International Conference on Image Processing. IEEE, 2015: 452—456.
- [60] Pan S J, Yang Q. A survey on transfer learning [J]. IEEE Transactions on Knowledge & Data Engineering, 2010, 22(10): 1345—1359.
- [61] Srdjan S, Marko A, Andras A. Deep neural networks based recognition of plant diseases by leaf image classification [J]. Computational Intelligence and Neuroscience, 2016(6): 1—11.
- [62] Liu B, Zhang Y, He D J. Identification of apple leaf diseases based on deep convolutional neural networks [J]. Symmetry, 2017, 10(1): 11.
- [63] Dyrmann M, Karstoft H, Midtiby H S. Plant species classification using deep convolutional neural network [J]. Biosystems Engineering, 2016, 151: 72—80.
- [64] Too E C, Li Y, Njuki S. A comparative study of fine-tuning deep learning models for plant disease identification [J]. Computers & Electronics in Agriculture, 2018.
- [65] Lecun Y, Bengio Y, Hinton G. Deep learning. [J]. Nature, 2015, 521(7553): 436.
- [66] Bekker A J, Goldberger J. Training deep neural networks based on unreliable labels [C]. IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2016: 2682—2686.
- [67] Rahنمءونfar M, Sheppard C. Deep count: fruit counting based on deep simulated learning [J]. Sensors, 2017, 17(4): 905.
- [68] Chen S W, Shivakumar S S, Dcunha S, et al. Counting apples and oranges with deep learning: a data-driven approach [J]. IEEE Robotics and Automation Letters, 2017, 2(2): 781—788.
- [69] Tang J L, Wang D, Zhang Z G. Weed identification based on K-means feature learning combined with convolutional neural network [J]. Computers & Electronics in Agriculture, 2017, 135: 63—70.

Application of machine learning in plant diseases recognition

Wang Dan¹, Chai Xiujuan^{1, 2}

(1. Agricultural Information Institute of Chinese Academy of Agricultural Sciences, Beijing, 100081, China;
2. Key Laboratory of Agricultural Big Data, Ministry of Agriculture and Rural Affairs, Beijing, 100081, China)

Abstract: Plant diseases recognition plays important role in plant growth process. It can not only provide the most powerful basis for eliminating diseases, but also reduce certain economic losses. As machine learning has been successfully applied in various domains, it has entered also the domain of plant diseases recognition. In this paper, we performed a survey of the application of machine learning technology in plant diseases recognition. We examined the main characteristics of plant diseases under study, the classical models and frameworks employed, the sources, nature and pre-processing of data used, and the overall performance achieved according to the metrics used at each work under study. On the basics of analyzing the technical transformation from traditional machine learning to deep learning in the application of pattern recognition, the developing trends of plant diseases recognition technologies were prospected, and the advantages of deep learning in this application were presented. Thus, we advocated the use of deep learning and analyzed the challenges of current research. For future work, we encourage researchers to develop more advanced learning architectures. It is also important to emphasize that the image databases used in the experiments is the most basic requirement. To address this problem, some datasets were made openly and freely available as collected in this article.

Keywords: machine learning; deep learning; plant diseases recognition

(上接第 163 页)

[11] 范琼, 张武, 张雪花, 等. 温室小气候环境监测预警技术及应用研究[J]. 中国农机学报, 2016, 37(5): 71—75.
Fan Qiong, Zhang Wu, Zhang Xuehua, et al. Research on

forewarning technology and application for greenhouse microclimate monitoring [J]. Journal of Chinese Agricultural Mechanization, 2016, 37(5): 71—75.

Research on digital farmland information monitoring system based on Internet of Things technology

Wang Maoli^{1, 2}, Wang Hao^{1, 2}, Dong Zhenzhen^{1, 2}, Tang Yongwei², Duan Jie^{1, 2}

(1. College of Information and Control Engineering, Qingdao University of Technology, Qingdao, 266520, China;
2. Qilu University of Technology (Shandong Academy of Sciences), Shandong Computer Science Center (National Supercomputer Center in Jinan), Shandong Provincial Key Laboratory of Computer Networks, Jinan, 250014, China)

Abstract: With the acceleration of urbanization in China, the agricultural development of our country is changing from the traditional agricultural production model to the modern agricultural production mode. Under this background, a digital farmland information monitoring system based on the Internet of things technology is studied. Firstly, the present situation of agricultural production in China is analyzed, and the monitoring system is divided into three parts: information collection terminal, LoRa gateway and information monitoring platform. The overall design structure of hardware is established. The microcontroller selects MSP430 series single chip computer, adopts LoRa wireless communication technology to transmit the data. When the acquisition terminal carries on the data transmission in the range of 2 000 m through LoRa, the loss rate is less than 3% and meets the requirements of data transmission. The power supply mode of “solar energy 3.7 V lithium battery” is adopted to supply power to the system, which ensures the system to work for a long time. Through the test, it is found that the lithium battery of the acquisition terminal can work normally for more than 143 days and meet the normal acquisition demand. The main program flow chart and working sequence diagram of each acquisition node and function module are drawn up by using IAR Embedded Workbench development tool, so that the user can observe the growth of crops at all times and ensure their healthy growth. The whole monitoring system meets the needs of farmers for farmland environmental monitoring and is of great significance for promoting the level of modern agricultural production informatization.

Keywords: Internet of Things technology; digital farmland; information monitoring; MSP430; LoRa wireless communication